

## Regression & Correlation

CORRELATIONS	1
1. simple correlation	1
2. Correlation Matrix	3
REGRESSION: BASICS	6
1. รู้จักข้อมูลของเรา	6
2. สร้างกราฟดูรูปแบบก่อน	7
3. สร้างสมการเส้นตรงอธิบายข้อมูลดีกว่า	8
4. ข้อมูลของเราฟิตกับโมเดลดีแค่ไหน	10
5. Regression ทดสอบอะไร	11
6. ทำความเข้าใจกับ output ที่เราได้มาจาก regression	14
7. สรุปวิธีการทำ regression แบบรวบรัด	15

---

## Correlations

### 1. simple correlation


หลาย ๆ ครั้ง เวลาที่เราต้องการศึกษาความสัมพันธ์ระหว่าง 2 ตัวแปร เรามักจะไม่ทราบว่า ตัวไหนเป็นสาเหตุ ตัวไหนเป็นผลลัพธ์ แต่เรายังอยากรู้ว่า 2 ตัวแปรนั้นมีความสัมพันธ์กันหรือไม่ ซึ่งเรายังสามารถทราบได้ โดยการหาสหสัมพันธ์ (correlation)

เราลองมาดูข้อมูล Australian Soybean ของเรากันอีกครั้งหนึ่ง

```
## # A tibble: 464 x 10
##   env   loc   year gen   yield height lodging size protein oil
##   <chr> <chr> <dbl> <chr> <dbl>   <dbl>   <dbl> <dbl>   <dbl> <dbl>
## 1 L70   Lawes  1970 G01    2.39   1.44     4.25   8.45   36.7  20.9
## 2 L70   Lawes  1970 G02    2.28   1.45     4.25   9.95   37.6  20.7
## # ...
```

ในตารางข้อมูลนี้เรามีข้อมูลเกี่ยวกับคุณภาพของถั่วเหลืองหลายอย่าง เช่น **size oil** และ **protein** เราจะเริ่มดูจากความสัมพันธ์ระหว่าง protein กับ oil ก่อน วิธีที่ดีที่สุด คือ เริ่มจากการวาดกราฟให้ตัวเองเห็นภาพก่อน

```
ggplot(soy, aes(x = protein, y = oil)) +
  geom_point()
```



ดูจากกราฟแล้วก็น่าจะมีความสัมพันธ์กัน เราสามารถตรวจสอบความสัมพันธ์ของ oil และ protein อย่างเป็นทางการด้วยการใช้ฟังก์ชัน `cor.test`

```
cor.test(soy$protein, soy$oil)

##
## Pearson's product-moment correlation
##
## data: soy$protein and soy$oil
## t = -24.956, df = 462, p-value < 2.2e-16
## alternative hypothesis: true correlation is not equal to 0
## 95 percent confidence interval:
## -0.7939767 -0.7160695
## sample estimates:
## cor
## -0.75771
```

มีสองอย่างที่สำคัญจากผลทดสอบนี้ คือ

- 1) **P-values:** บอกว่าความสัมพันธ์นี้มีนัยสำคัญหรือไม่ (ความสัมพันธ์นี้มีสมมติฐานไม่เป็น 0 จริงไหม ถ้าต่างจริง P จะต้องน้อยกว่าหรือเท่ากับ 0.05
- 2) **cor:** คือ สัมประสิทธิ์สหสัมพันธ์ (correlation coefficient) เป็นตัวบอกความรุนแรงของความสัมพันธ์นั้น ๆ กล่าวคือ
  - $cor = 0$  หมายถึง ไม่มีความสัมพันธ์ใด ๆ
  - $cor = 1$  คือ มีความสัมพันธ์เชิง**บวก** (**positive** relationship) อย่างรุนแรงที่สุด (x เพิ่ม y เพิ่ม)
  - $cor = -1$  คือ มีความสัมพันธ์เชิง**ลบ** (**negative** relationship) อย่างรุนแรงที่สุด (x เพิ่ม y ลด)

ในกรณีนี้เรามีความสัมพันธ์เชิงลบที่มีนัยสำคัญ ( $cor = -0.75$ ,  $P < 0.001$ ) ระหว่าง **protein** และ **oil** ซึ่งหมายความว่าปริมาณน้ำมันมีแนวโน้มที่จะลดลงเมื่อปริมาณโปรตีนเพิ่มขึ้น

## 2. Correlation Matrix

ในโลกที่เต็มไปด้วยข้อมูลอย่างทุกวันนี้ เราอาจจะไม่มีเวลายามานั่งดูทีละตัวแปรทีละคู่ เรามีวิธีที่จะพิจารณาตัวแปรทุกคู่พร้อม ๆ กันในเวลาเดียวกันดังนี้

เริ่มแรกจากเลือกข้อมูลแค่บางส่วนมาวิเคราะห์ด้วยฟังก์ชัน `select`

```
soy2 <- soy %>%  
  select(height, yield, size, protein, oil)
```

หลังจากนั้นเราสามารถหาค่า `rcorr` จาก package `Hmisc` เพื่อวิเคราะห์หลาย ๆ ตัวแปรพร้อมกันทีเดียว

```
library(Hmisc)  
  
rcorr(as.matrix(soy2))  
  
##           height yield  size protein  oil  
## height      1.00 -0.22 -0.52   0.28 -0.50  
## yield      -0.22  1.00  0.51  -0.34  0.54  
## size       -0.52  0.51  1.00  -0.41  0.76  
## protein     0.28 -0.34 -0.41   1.00 -0.76  
## oil        -0.50  0.54  0.76  -0.76  1.00  
##  
## n= 464  
##  
##  
## P  
##           height yield  size protein  oil  
## height           0      0      0      0  
## yield            0      0      0      0  
## size             0      0      0      0  
## protein          0      0      0      0  
## oil              0      0      0      0
```

ตัวเลขใน matrix ด้านบนคือค่าสัมประสิทธิ์ของสหสัมพันธ์ ส่วน matrix ด้านล่างแสดงค่า P-value ของความสัมพันธ์นั้น ๆ

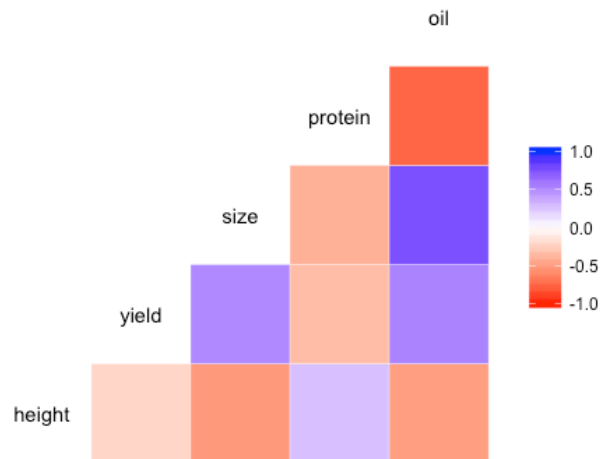
ตัวอย่างเช่น

ซึ่งอาจจะดูยากสักหน่อยเราสามารถดูความสัมพันธ์ได้ง่ายขึ้นในรูปกราฟโดย `GGally` และ `corrplot`

วิธีที่ 1 `ggcorr` แสดงเฉพาะสีตามความสัมพันธ์จากค่าสัมประสิทธิ์

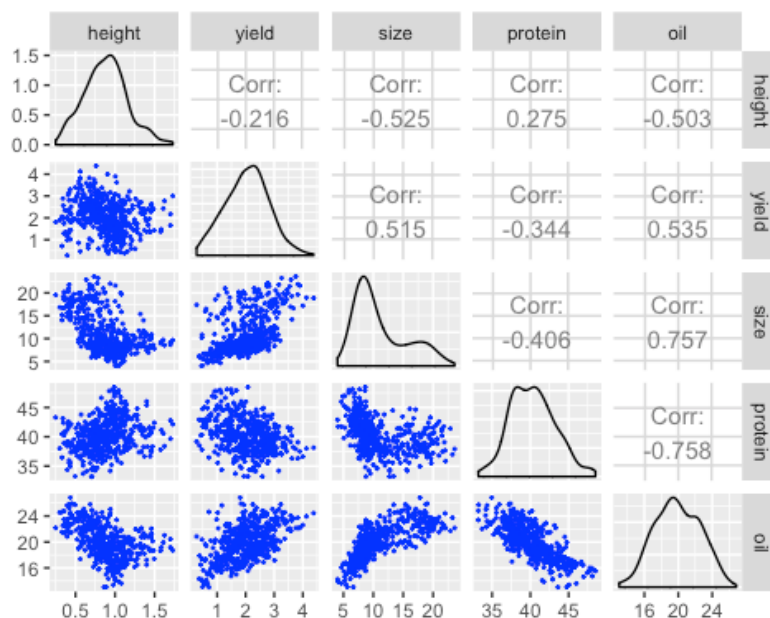
```
library(GGally)
```

```
ggcorr(soy2, low = "red", mid = "white", high = "blue")
```



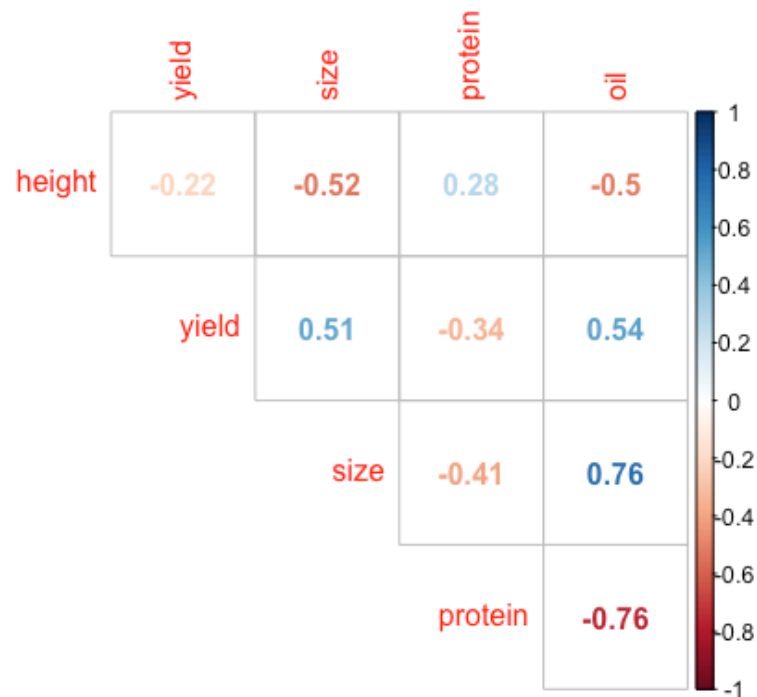
วิธีที่ 2 `ggpairs` จะแสดงทั้งข้อมูลดิบ การกระจายของข้อมูล และ ค่าสัมประสิทธิ์ความสัมพันธ์เป็นตัวเลข

```
ggpairs(soy2, lower = list(continuous = wrap("points", size = 0.3, color = "blue")))
```




วิธีที่ 3 `corrplot` สามารถแสดงผลสัมประสิทธิ์สหสัมพันธ์ได้หลายวิธีเช่น .....

```
library(corrplot)
cor.soy <- cor(soy2)
corrplot(cor.soy, type = "upper", method = "number", diag = F)
```



```
corrplot(cor.soy, type = "lower", method = "circle", diag = F)
```



## Regression: Basics

การวิเคราะห์สมการถดถอย (regression) คือการหาความสัมพันธ์ระหว่างตัวแปรต้น (independent variable) และ ตัวแปรตาม (dependent variable) ที่เป็นตัวแปรต่อเนื่องทั้งสองตัวแปร โดยเราสนใจว่าตัวแปรต้นมีผลต่อตัวแปรตามมากน้อยเพียงไร โดยวันนี้จะได้มาทำความเข้าใจเกี่ยวกับวิธีการทางสถิติที่ใช้อธิบายความสัมพันธ์เหล่านี้นั่นกัน

### 1. รู้จักข้อมูลของเรา

เราจะใช้ข้อมูลจากการทดลองเกี่ยวกับการเพิ่มน้ำหนักของหนูซึ่งมีหน้าตาแบบนี้

```
## # A tibble: 50 x 5
##   treatment rep   feed weight1 gain
##   <chr>      <chr> <dbl>   <dbl> <dbl>
## 1 T1        R1      674     30   165
## 2 T1        R2      628     21   156
## 3 T1        R3      661     21   159
## 4 T1        R4      694     33   167
## 5 T1        R5      713     27   170
## 6 T1        R6      585     24   146
## 7 T1        R7      575     20   130
## 8 T1        R8      638     29   151
## 9 T1        R9      632     28   164
## 10 T1       R10     637     26   158
## # ... with 40 more rows
```

โดยมีคอลัมน์ต่อไปนี้

- **treatment** คือ ชนิดของอาหารที่ให้กับหนูแต่ละตัว
- **rep** คือ แต่ละซ้ำ (replication) ก็คือหนูแต่ละตัวนั่นเอง
- **feed** คือ ปริมาณอาหารที่หนูแต่ละตัวกินเข้าไประหว่างการทดลอง
- **weight1** คือ น้ำหนักของหนูก่อนเริ่มต้นการทดลอง
- **gain** คือ น้ำหนักของหนูที่เพิ่มขึ้นหลังจากการทดลอง

เราจะลองมาวิเคราะห์ความสัมพันธ์ระหว่างปริมาณอาหาร (feed) และ น้ำหนักที่เพิ่มขึ้น (gain) เราคิดว่า....


ตัวแปรต้น คือ ....

ตัวแปรตาม คือ ...

สมมติฐานก็คือ ....


## 2. สร้างกราฟดูรูปแบบก่อน

เช่นเคย สิ่งแรกที่เราจะต้องทำคือการสร้างกราฟเพื่อแสดงความสัมพันธ์ระหว่างตัวแปรทั้งสองดังนี้



แนวโน้มเป็นอย่างไร ปริมาณอาหารมีผลต่อน้ำหนักจริงหรือไม่

เราลองใส่เส้นแนวโน้ม (trend line) แบบเส้นตรงลงไป ด้วยฟังก์ชัน `geom_smooth`



สิ่งที่เราทำอยู่คือการใส่สมการเส้นตรง (linear equation/linear model) ลงไปในข้อมูลของเราเพื่ออธิบายข้อมูล

เราคิดว่าสมการเส้นตรงนี้อธิบายข้อมูลเราได้ดีพอไหม?

### 3. สร้างสมการเส้นตรงอธิบายข้อมูลดีกว่า

เราจะใช้ฟังก์ชัน `lm` เพื่อสร้างสมการเส้นตรงเพื่ออธิบายข้อมูลของเราดังนี้

```
pig.lm <- lm(gain ~ feed, data = pig)
pig.lm

## Call:
## lm(formula = gain ~ feed, data = pig)
##
## Coefficients:
## (Intercept)      feed
##      5.0319      0.2432
```

สมการที่เราสร้างนี้ คือ สมการที่น้ำหนักที่เพิ่มขึ้น (`gain`) เป็นผลมาจากอาหารที่กินเข้าไป (`feed`) ซึ่งมีจุดตัดแกน `y` (`intercept`) และ ความชัน (`slope`) หรือ `feed` ใน `output` นี้ ซึ่งเขียนเป็นสมการง่ายๆได้แบบนี้

$$\text{gain} = \text{intercept} + \text{slope} \times \text{gain} = 5.0319 + 0.2432 \times \text{gain}$$

ซึ่งสามารถเขียนเป็นรูปสมการอย่างเป็นทางการได้แบบนี้

$$\hat{y}_i = \alpha + \beta \times x_i$$

โดยที่


$\hat{y}_i$  = ค่า `y` ที่ได้จากสมการ

$\alpha$  = จุดตัดแกน `y`

$\beta$  = ความชัน

$x_i$  = ค่า `x` ของแต่ละค่าในสมการ

ซึ่งถ้าเรานำข้อมูลข้างต้นมาวาดเป็นกราฟเส้นตรง จะได้เป็นกราฟแบบนี้





### 3.1 จุดตัด (intercept) คืออะไร

ลองกลับไปดูที่สมการอีกครั้ง

$$\hat{y}_i = \alpha + \beta \times x_i$$

ถ้าเราต้องการทราบว่า  $\alpha$  หรือจุดตัดแกน y คืออะไร เราจะต้องทำให้พจน์ที่สองเป็นศูนย์ ซึ่งวิธีที่ง่ายที่สุดก็คือการทำให้  $x_i$  เป็น 0 จึงได้ออกมาแบบนี้

$$\hat{y}_i = \alpha$$

แปลง่าย ๆ ก็คือ ค่า y ที่จะได้เมื่อค่า x เป็น 0 หรือในบริบทของข้อมูลของเรา ก็คือ น้ำหนักของหนูที่เพิ่มขึ้น (gain) เมื่อไม่ให้อาหารอะไรเลย (feed = 0)


เราคิดว่าเป็นไปได้ไหมที่หนูจะมีน้ำหนักเพิ่มเมื่อไม่ให้อาหารอะไรเลย

### 3.2 ความชัน (slope) คืออะไร

Slope หรือ ความชัน คือ การเพิ่มขึ้นของค่า y เมื่อค่า x เพิ่มขึ้น โดยสามารถเขียนสูตรคำนวณได้อย่างเป็นทางการได้แบบนี้:


$$\text{slope} = \frac{y_2 - y_1}{x_2 - x_1}$$

ในบริบทของข้อมูลนี้ ก็คือ น้ำหนักของหนูที่เพิ่มขึ้นเมื่อเพิ่มอาหารขึ้นมา ถ้าชันมากขึ้น แปลว่าเพิ่มปริมาณอาหารเท่ากัน น้ำหนักสามารถเพิ่มขึ้นได้เร็วขึ้นกว่าเดิม ในอีกมุมก็คือว่า ปริมาณอาหารมีผลต่อน้ำหนักเพิ่มขึ้นเท่าไร



## 4. ข้อมูลของเราฟิตกับโมเดลแค่ไหน

ลองกลับมาดูกราฟอีกรอบหนึ่ง



จะเห็นว่าข้อมูลของเราไม่ฟิตเปรี๊ยะกับเส้น regression ที่เราสร้างขึ้น เพราะข้อมูลที่ไหนในโลกจะ perfect ขนาดนั้นก็คงไม่มี ดังนั้น **ตัวข้อมูล** ของเราจะประพจน์ตัวคล้ายกับสมการเส้นตรง แต่ไม่ใช่เส้นตรงเสียทีเดียว ตามนี้

$$y_i = \alpha + \beta \times x_i + \epsilon_i$$

$y_i$  และ  $x_i$  ที่ไม่มีหมวก หมายถึง ค่าข้อมูลจริง ๆ

$\epsilon_i$  หมายถึง ค่าความคลาดเคลื่อนของแต่ละจุดข้อมูล ที่เป็นผลมาจากตัวแปรอื่น ๆ ที่ไม่ใช่ตัวแปรที่เราสนใจ

ในกรณีของเราที่พิจารณาผลของปริมาณอาหารที่ให้ (feed) เป็นตัวแปรเดียว จะทำให้เราอธิบายการเพิ่มขึ้นของน้ำหนักของหมูได้เพียงบางส่วนเท่านั้น เพราะว่าปริมาณอาหารที่ให้ ไม่ใช่เพียงปัจจัยเดียวที่ทำให้น้ำหนักหมูขึ้น อาจจะมีปัจจัยอื่น ๆ ด้วย จุดข้อมูล จึงไม่ได้อยู่บนเส้นสมการเส้นตรงทั้งหมด

ถ้าความคลาดเคลื่อนมาก จุดข้อมูลก็จะกระจายออกจากเส้นมากเท่านั้น ลองไปทดสอบความเข้าใจเราเกี่ยวกับความคลาดเคลื่อนและความชันในโมเดล ได้ที่ <https://ekraichak.shinyapps.io/regression/>


## 5. Regression ทดสอบอะไร

### 5.1 สมการเส้นตรงของเราทำงานได้ดีแค่ไหน?

เราสามารถวัดความสามารถของสมการเส้นตรงในการอธิบายชุดข้อมูลของเราได้ โดยวัดว่า จุดข้อมูลนั้นอยู่ห่างหรือแตกต่างจากเส้นสมการมากเท่าไร เราเรียกความแตกต่างนี้ว่า **residuals** ซึ่งสามารถคำนวณได้ดังนี้

$$\text{residuals} = y_i - \hat{y}_i = y_i - (\alpha + \beta \times x_i)$$

$\hat{y}_i$  ก็คือค่าของ  $y$  ที่ได้จากสมการในการพยายามเอาเส้นตรงมาอธิบายข้อมูลของเรา ซึ่งก็ได้มาจากสมการเส้นตรงปกติก็คือ  $\alpha + \beta \times \hat{x}_i$  โดยเราสามารถมองเห็น residual ได้ตามภาพนี้



สมการหรือโมเดลที่อธิบายข้อมูลได้ดี ก็คือ สมการที่มีค่า residuals น้อยมากที่สุดเท่าที่เป็นไปได้ ซึ่งในกรณีของเรา ก็เหมือนจะมีความแตกต่างระหว่างจุดกับตัวเส้นอยู่พอสมควร แล้วเมื่อไหร่ที่เราจะเรียกว่าน้อยพอ เราจึงต้องมีวิธีการคำนวณ residuals ทั้งหมด หรือการคำนวณค่าที่เรียกว่า **residual sum of square ( $SS_{\text{residuals}}$ )**

$$SS_{\text{residuals}} = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$


ซึ่งค่านี้ไม่ใช่อะไรพิเศษ ก็แค่ความแตกต่างระหว่างจุดข้อมูล ( $y_i$ ) และค่าที่สมการให้มา ( $\hat{y}_i$ ) แล้วนำไปยกกำลังสอง เพื่อให้ทั้งบวกและลบมีเครื่องหมายเป็นบวกทั้งหมด แล้วจึงมาจับรวมกัน **หน้าที่หลักของการวิเคราะห์ regression คือ ทำให้สมการนั้นมีค่า  $SS_{\text{residuals}}$  น้อยที่สุด** (ซึ่งมีวิธีการ proof ค่อนข้างจะยากเกินขอบเขตของวิชานี้ เอาเป็นว่ามีวิธีการละกัน) เราเรียกวิธีการนี้ว่า **Ordinary Least Square (OLS) Estimation**

แล้วเราจะรู้ได้อย่างไรว่า  $SS_{\text{residuals}}$  ที่เราคำนวณได้มันมากหรือน้อยอย่างไร เราจึงต้องมีตัวเทียบโดยการคำนวณ sum of square อีกสองแบบได้แก่

### 1. regression sum of square ( $SS_{regression}$ )

$$SS_{regression} = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$$


อันนี้เป็น sum of square ของตัวเส้น regression ว่าแตกต่างจากค่าเฉลี่ยของ  $y$  ( $\bar{y}$ ) การคำนวณนี้ เป็นการดูว่า เส้น regression ที่วาดมานี้แตกต่างจากที่ไม่มีความสัมพันธ์เลยอย่างไร (เส้นแนวนอน ที่ทุกค่า  $x$  ค่า  $y$  เท่ากับค่าเฉลี่ยของ  $y$ )



### 2. total sum of square ( $SS_{total}$ )

$$SS_{total} = \sum_{i=1}^n (y_i - \bar{y})^2$$

อันนี้เป็น sum of square ของตัวจุดข้อมูล ว่าแตกต่างจากค่าเฉลี่ยของ  $y$  ( $\bar{y}$ ) การคำนวณนี้ เป็นการดูว่า จุดข้อมูลนี้เป็นอย่างไรเมื่อเทียบกับไม่มีความสัมพันธ์เลยอย่างไร และด้วยความที่ sum of square นี้เป็นส่วนที่ความคาดเคลื่อนมากที่สุดจึงมีคุณสมบัติคือ  $SS_{total} = SS_{residuals} + SS_{regression}$



ในการตัดสินใจว่าสมการของเราทำงานดีแค่ไหน เราจะคำนวณ the *coefficient of determinant* หรือ  $R^2$  ด้วยสูตรนี้

$$R^2 = \frac{SS_{regression}}{SS_{total}} = 1 - \frac{SS_{residuals}}{SS_{total}}$$

ดังนั้น  $R^2 = 1$  เป็นโมเดลที่สมบูรณ์แบบ อธิบายทุกอย่างในข้อมูลเรา,  $R^2 = 0$  เป็นโมเดลที่แย่มาก (ไม่อธิบายอะไรเลย  $SS_{residuals} = SS_{total}$ )

เราสามารถคำนวณ sum of square ด้วยฟังก์ชัน `anova()`.

```
## Analysis of Variance Table
##
## Response: gain
##           Df Sum Sq Mean Sq F value    Pr(>F)
## feed       1  9131.0   9131.0   87.949 1.985e-12 ***
## Residuals 48  4983.4    103.8
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

ในกรณีนี้,  $SS_{regression}$  คือ Sum sq สำหรับ feed ดังนั้น  $SS_{total}$  ก็คือผลรวมของคอลัมน์ Sum sq ดังนั้นเราก็จะสามารถคำนวณ  $R^2$  ได้ดังนี้

$$R^2 = \frac{9131.0}{9131.0 + 4983.4} = 0.64$$

หรืออธิบายแบบง่าย ๆ ว่า ตัวแปร feed อธิบายประมาณ 64% ของข้อมูลของเรา

## 5.2 ความชันของเราต่างจาก 0 หรือเปล่า?

ถ้า ความชัน หรือ slope ( $\beta$ ) ของสมการ regression เป็น 0 นั่นแปลว่าไม่มีความสัมพันธ์ระหว่างตัวแปร x และ ตัวแปร y นักสถิติจึงคิดวิธีตรวจสอบสมมติฐานนี้โดยมีวิธีการมาจาก t-test คือ

$$t = \frac{Observed - NoRelationship}{StandardError(SE)}$$

ในกรณีของ regression “No relationship” หมายความว่า slope ( $\beta$ ) = 0 ดังนั้น t-statistics จึงเหลือแค่

$$t = \frac{\beta_{observed}}{SE}$$

ซึ่งจะนำไปคำนวณหาค่า P-value เหมือนกับ t-test ปกติ

## 6. ทำความเข้าใจกับ output ที่เราได้มาจาก regression


เราสามารถดูผลสรุปของ regression ได้จากฟังก์ชัน `summary()`

```
##  
## Call:  
## lm(formula = gain ~ feed, data = pig)  
##  
## Residuals:  
##      Min       1Q   Median       3Q      Max   
## -28.291  -6.952   0.453   5.785  23.980  
  
## Coefficients:  
##              Estimate Std. Error t value Pr(>|t|)      
## (Intercept)  5.03188    17.60076   0.286   0.776      
## feed         0.24323     0.02594   9.378 1.98e-12 ***  
## ---  
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1  
  
## Residual standard error: 10.19 on 48 degrees of freedom  
## Multiple R-squared:  0.6469, Adjusted R-squared:  0.6396   
## F-statistic: 87.95 on 1 and 48 DF,  p-value: 1.985e-12
```

## 7. สรุปวิธีการทำ regression แบบรวบรัด

### Step 1 วาดกราฟเพื่อทราบ pattern

```
ggplot(pig, aes(x = feed, y = gain)) +  
  geom_point() +  
  geom_smooth(method = "lm", se = FALSE)
```



### Step 2 สร้าง linear model


```
pig.lm <- lm(gain ~ feed, data = pig)  
pig.lm  
  
##  
## Call:  
## lm(formula = gain ~ feed, data = pig)  
##  
## Coefficients:  
## (Intercept)      feed  
##      5.0319      0.2432
```

### Step 3 ใช้ summary ดูตัว model


```
summary(pig.lm)  
  
##  
## Call:  
## lm(formula = gain ~ feed, data = pig)  
##
```

```
## Residuals:
##      Min       1Q   Median       3Q      Max
## -28.291  -6.952   0.453   5.785  23.980
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  5.03188    17.60076   0.286   0.776
## feed         0.24323     0.02594   9.378 1.98e-12 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 10.19 on 48 degrees of freedom
## Multiple R-squared:  0.6469, Adjusted R-squared:  0.6396
## F-statistic: 87.95 on 1 and 48 DF, p-value: 1.985e-12
```


#### Step 4 แปลความผลจากตาราง summary




slope = 5.01     $R^2 = 0.99$      $P < 2.2 \times 10^{-16}$



slope = 0.74     $R^2 = 0.38$      $P < 4.75 \times 10^{-12}$



slope = 0.16     $R^2 = -0.008$      $P = 0.66$



slope = 4.73     $R^2 = 0.65$      $P < 2.2 \times 10^{-16}$

Slope:            ถ้าเป็น +

ถ้าเป็น -

ถ้าเป็นหรือใกล้ 0

R-square:        ใกล้ 0

ใกล้ 1

P-value slope:    $P \leq 0.05$

$P > 0.05$